

▼ Maestría en Inteligencia Artificial Aplicada

Curso: Ciencia y Analitica de Datos

Tecnológico de Monterrey

Profesor Titular: Maria de la Paz Rico Fernandez

Profesor Tutor: Juan Miguel Meza Méndez

Equipo 170

Freddy Armendariz Herrera - A01793672

Samuel Elias Flores Gonzalez - A01793668

Reto - Entrega 1 - Limpieza, Analisis, Visualizaicon, Kmeans

Fecha: 13 de Noviembre del 2022

```
# Incluye aquí todos módulos, librerías y paquetes que requieras.
```

```
# Descargar Data Set
```

```
# =====  
import requests, zipfile  
from io import BytesIO
```

```
# Tratamiento de datos
```

```
# =====  
import numpy as np  
import pandas as pd
```

```
# Graficos
```

```
# =====  
import seaborn as sns  
import matplotlib.pyplot as plt
```

```
# Preprocesado y modelado
```

```
# =====  
from sklearn.model_selection import train_test_split  
from sklearn.pipeline import Pipeline  
from sklearn.compose import ColumnTransformer  
from sklearn.impute import SimpleImputer
```

```
from sklearn.preprocessing import MinMaxScaler, OneHotEncoder, StandardScaler
from sklearn.dummy import DummyRegressor
from sklearn.model_selection import RepeatedKFold
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.neural_network import MLPRegressor
from sklearn.model_selection import cross_validate
from sklearn.metrics import make_scorer
from tabulate import tabulate
from sklearn.model_selection import GridSearchCV
from sklearn.inspection import permutation_importance
from sklearn.preprocessing import LabelEncoder
```

Geopandas

=====

```
! pip install qeds fiona geopandas xgboost gensim folium pyLDAvis descartes
```

```
import geopandas as gpd
from shapely.geometry import Point
```

```
# Kmeans
```

=====

```
from sklearn.cluster import KMeans
```

Mapa

=====

```
import folium
```

COLLECTING 111g 111g 17=0.5

Downloading cligj-0.7.2-py3-none-any.whl (7.1 kB)

```
Requirement already satisfied: setuptools in /usr/local/lib/python3.7/dist-packages (44.0.0)
```

```
Requirement already satisfied: attrs>=17 in /usr/local/lib/python3.7/dist-packages (f
```

Collecting click-plugins>=1.0

Downloading click_plugins-1.1.1-py2.py3-none-any.whl (7.5 kB)

Requirement already satisfied: six>=1.7 in /usr/local/lib/python3.7/dist-packages (from

```
Requirement already satisfied: click>=4.0 in /usr/local/lib/python3.7/dist-packages (7.0)
```

Requirement already satisfied: shapely>=1.6 in /usr/local/lib/python3.7/dist-packages

Collecting pyproj>=2.2.0

Downloading pyproj-3.2.1-cp37-cp37m-manylinux2010_x86_64.whl (6.3 MB)

6.3 MB 60.5 MB/s

```
Requirement already satisfied: pytz>=2017.3 in /usr/local/lib/python3.7/dist-packages
```

```
Requirement already satisfied: python-dateutil>=2.7.3 in /usr/local/lib/python3.7/dist-packages
```

```
Requirement already satisfied: smart-open>=1.2.1 in /usr/local/lib/python3.7/dist-packages
```

Requirement already satisfied: jinja2>=2.9 in /usr/local/lib/python3.7/dist-packages

Requirement already satisfied: branca>=0.3.0 in /usr/local/lib/python3.7/dist-package

Requirement already satisfied: MarkupSafe>=0.23 in /usr/local/lib/python3.7/dist-pack

Collecting sklearn

Downloading sklearn-0.0.post1.tar.gz (3.6 kB)

Requirement already satisfied: numexpr in /usr/local/lib/python3.7/dist-packages (from

Requirement already satisfied: joblib in /usr/local/lib/python3.7/dist-packages (from

```
Requirement already satisfied: future in /usr/local/lib/python3.7/dist-packages (from
```

Collecting funds.

```

Collecting tuncy
  Downloading funcy-1.17-py2.py3-none-any.whl (33 kB)
Requirement already satisfied: kiwisolver>=1.0.1 in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: cycycler>=0.10 in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: pyparsing!=2.0.4,!=2.1.2,!=2.1.6,>=2.0.1 in /usr/local
Requirement already satisfied: typing-extensions in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: et-xmlfile in /usr/local/lib/python3.7/dist-packages (
Requirement already satisfied: lxml in /usr/local/lib/python3.7/dist-packages (from p
Requirement already satisfied: chardet<4,>=3.0.2 in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: urllib3!=1.25.0,!=1.25.1,<1.26,>=1.21.1 in /usr/local/
Requirement already satisfied: idna<3,>=2.5 in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: tenacity>=6.2.0 in /usr/local/lib/python3.7/dist-packages
Collecting inflection>=0.3.1
  Downloading inflection-0.5.1-py2.py3-none-any.whl (9.5 kB)
Requirement already satisfied: more-itertools in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: numba in /usr/local/lib/python3.7/dist-packages (from
Requirement already satisfied: sympy in /usr/local/lib/python3.7/dist-packages (from
Requirement already satisfied: importlib-metadata in /usr/local/lib/python3.7/dist-packages
Requirement already satisfied: llvmlite<0.40,>=0.39.0dev0 in /usr/local/lib/python3.7
Requirement already satisfied: zipp>=0.5 in /usr/local/lib/python3.7/dist-packages (f
Requirement already satisfied: threadpoolctl>=2.0.0 in /usr/local/lib/python3.7/dist-
Requirement already satisfied: patsy>=0.5 in /usr/local/lib/python3.7/dist-packages (
Requirement already satisfied: mpmath>=0.19 in /usr/local/lib/python3.7/dist-packages
Building wheels for collected packages: qeds, pyLDAvis, sklearn
  Building wheel for qeds (setup.py) ... done
  Created wheel for qeds: filename=qeds-0.7.0-py3-none-any.whl size=27812 sha256=efea
  Stored in directory: /root/.cache/pip/wheels/fc/8c/52/0cc036b9730b75850b9845770780f
  Building wheel for pyLDAvis (PEP 517) ... done
  Created wheel for pyLDAvis: filename=pyLDAvis-3.3.1-py2.py3-none-any.whl size=13689
  Stored in directory: /root/.cache/pip/wheels/c9/21/f6/17bcf2667e8a68532ba2fbf6d5c72
  Building wheel for sklearn (setup.py) ... done
  Created wheel for sklearn: filename=sklearn-0.0.post1-py3-none-any.whl size=2344 sh
  Stored in directory: /root/.cache/pip/wheels/42/56/cc/4a8bf86613aafd5b7f1b310477667
Successfully built qeds pyLDAvis sklearn
Installing collected packages: munch, inflection, cliq, click-plugins, sklearn, quan

```

▼ Eleccion de una base de datos

```

# Extraccion de la carpeta comprimida
url = "http://201.116.60.46/Datos_de_calidad_del_agua_de_5000_sitios_de_monitoreo.zip"
req = requests.get(url)
zipfile.ZipFile(BytesIO(req.content)).extractall()

# Lectura del csv como dataframe
path = "Datos_de_calidad_del_agua_2020/Datos_de_calidad_del_agua_de_sitios_de_monitoreo_de_ag
df=pd.read_csv(path, encoding="latin1")

# Datos de la calidad de aguas superficiales
df.head()

```

	CLAVE	SITIO	ORGANISMO_DE_CUENCA	ESTADO	MUNICIP
0	DLAGU6	POZO SAN GIL	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	ASIENTO
1	DLAGU6516	POZO R013 CAÑADA HONDA	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	AGUASCALIENTE
2	DLAGU7	POZO COSIO	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	COS
3	DLAGU9	POZO EL SALITRILLO	LERMA SANTIAGO PACIFICO	AGUASCALIENTES	RINCON I ROMO
4	DLBAJ107	RANCHO EL TECOLOTE	PENINSULA DE BAJA CALIFORNIA	BAJA CALIFORNIA SUR	LA P

5 rows × 57 columns



▼ Limpieza de los datos

```
# Se verifica la cantidad de datos nulos en cada columna
df.isna().sum()
```

CLAVE	0
SITIO	0
ORGANISMO_DE_CUENCA	0
ESTADO	0
MUNICIPIO	0
ACUIFERO	0
SUBTIPO	0
LONGITUD	0
LATITUD	0
PERIODO	0
ALC_mg/L	4
CALIDAD_ALC	4
CONDUCT_mS/cm	6
CALIDAD_CONDUC	6
SDT_mg/L	1068
SDT_M_mg/L	2
CALIDAD_SDT_ra	2
CALIDAD_SDT_salin	2
FLUORUROS_mg/L	0
CALIDAD_FLUO	0
DUR_mg/L	1
CALIDAD_DUR	1
COLI_FEC_NMP/100_mL	0
CALIDAD_COLI_FEC	0

```

N_NO3_mg/L      1
CALIDAD_N_NO3    1
AS_TOT_mg/L      0
CALIDAD_AS        0
CD_TOT_mg/L      0
CALIDAD_CD        0
CR_TOT_mg/L      0
CALIDAD_CR        0
HG_TOT_mg/L      0
CALIDAD_HG        0
PB_TOT_mg/L      0
CALIDAD_PB        0
MN_TOT_mg/L      0
CALIDAD_MN        0
FE_TOT_mg/L      0
CALIDAD_FE        0
SEMAFORO         0
CONTAMINANTES    434
CUMPLE_CON_ALC    0
CUMPLE_CON_COND   0
CUMPLE_CON_SDT_ra 0
CUMPLE_CON_SDT_salin 0
CUMPLE_CON_FLUO   0
CUMPLE_CON_DUR    0
CUMPLE_CON_CF     0
CUMPLE_CON_NO3    0
CUMPLE_CON_AS     0
CUMPLE_CON_CD     0
CUMPLE_CON_CR     0
CUMPLE_CON_HG     0
CUMPLE_CON_PB     0
CUMPLE_CON_MN     0
CUMPLE_CON_FE     0
dtvne: int64

```

Se descartan las columnas de CONTAMINANTES y SDT_mg/L ya que la mayor parte de sus datos son
`df.drop(["CONTAMINANTES", "SDT_mg/L"], inplace=True, axis=1)`

Las demás columnas presentaban un 6 datos nulos como máximo, estos se pueden considerar despreciables, por lo que se procede a eliminarlos.

```

#Eliminamos los datos NaN
df.dropna(inplace = True)

```

```

#Se corrobora si quedo algún dato vacío, False = No hay datos nulos
df.isna().values.any()

```

```
False
```

Al analizar el set de datos, se puede inferir que los datos categóricos son dependientes de los datos numéricos, es decir, hacen referencia a ellos, provocando así una redundancia en los

mismos, por lo tanto se procede a eliminar estas columnas y utilizar solo las numericas.

```
col_num = ['LONGITUD', 'LATITUD', 'ALC_mg/L', 'CONDUCT_mS/cm', 'SDT_M_mg/L', 'FLUORUROS_mg/L', 'DUR_mg/L', 'N_NO3_mg/L', 'AS_TOT_mg/L', 'CD_TOT_mg/L', 'CR_TOT_mg/L', 'HG_TOT_mg/L', 'PB_TOT_mg/L']
df_new = df[col_num]
df_new.head()
```

	LONGITUD	LATITUD	ALC_mg/L	CONDUCT_mS/cm	SDT_M_mg/L	FLUORUROS_mg/L	DUR_m
0	-102.02210	22.20887	229.990	940.0	603.6	0.9766	213.
1	-102.20075	21.99958	231.990	608.0	445.4	0.9298	185.0
2	-102.28801	22.36685	204.920	532.0	342	1.8045	120.
3	-102.29449	22.18435	327.000	686.0	478.6	1.1229	199.
4	-110.24480	23.45138	309.885	1841.0	1179	0.2343	476.9

Se comprueba la cantidad de datos nulos por columna y su tipo de dato
df_new.info()

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1054 entries, 0 to 1067
Data columns (total 17 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   LONGITUD                             1054 non-null   float64
1   LATITUD                             1054 non-null   float64
2   ALC_mg/L                             1054 non-null   float64
3   CONDUCT_mS/cm                       1054 non-null   float64
4   SDT_M_mg/L                           1054 non-null   object
5   FLUORUROS_mg/L                       1054 non-null   object
6   DUR_mg/L                             1054 non-null   object
7   COLI_FEC_NMP/100_mL                 1054 non-null   object
8   N_NO3_mg/L                           1054 non-null   object
9   AS_TOT_mg/L                          1054 non-null   object
10  CD_TOT_mg/L                          1054 non-null   object
11  CR_TOT_mg/L                          1054 non-null   object
12  HG_TOT_mg/L                          1054 non-null   object
13  PB_TOT_mg/L                          1054 non-null   object
14  MN_TOT_mg/L                          1054 non-null   object
15  FE_TOT_mg/L                          1054 non-null   object
16  SEMAFORO                             1054 non-null   object
dtypes: float64(4), object(13)
memory usage: 148.2+ KB
```

Se aprecia como en la mayor parte de las columnas son de tipo string (object) aunque son numericas, y esto se debe a que incluyen el simbolo <.

```
# Conversion de tipo de dato de la columna y eliminacion del <
col = ['ALC_mg/L', 'CONDUCT_mS/cm', 'SDT_M_mg/L', 'FLUORUROS_mg/L', 'DUR_mg/L', 'COLI_FEC_NMP/100_
      'AS_TOT_mg/L', 'CD_TOT_mg/L', 'CR_TOT_mg/L', 'HG_TOT_mg/L', 'PB_TOT_mg/L', 'MN_TOT_mg/L', 'F
for name in col:
    df_new[name] = df_new[name].astype(str)
    df_new[name] = df_new[name].replace("<", "", regex=True)
    df_new[name] = df_new[name].astype(float)
```

```
df_new.head()
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:5: SettingWithCopyWar
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead
```

```
See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable
"""
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:6: SettingWithCopyWar
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead
```

```
See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:7: SettingWithCopyWar
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead
```

```
See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable
import sys
```

	LONGITUD	LATITUD	ALC_mg/L	CONDUCT_mS/cm	SDT_M_mg/L	FLUORUROS_mg/L	DUR_m
0	-102.02210	22.20887	229.990	940.0	603.6	0.9766	213.7
1	-102.20075	21.99958	231.990	608.0	445.4	0.9298	185.0
2	-102.28801	22.36685	204.920	532.0	342.0	1.8045	120.7
3	-102.29449	22.18435	327.000	686.0	478.6	1.1229	199.8
4	-110.24480	23.45138	309.885	1841.0	1179.0	0.2343	476.9

Se prosigue dividiendo este conjunto de datos en tres partes dependiendo de su categoria.

```
df_location = df_new[["LONGITUD", "LATITUD"]] # Localizacion
df_sust = df_new.drop(["LONGITUD", "LATITUD", "SEMAFORO"], axis=1) # Sustancias contaminantes
y = pd.DataFrame(df_new["SEMAFORO"])# Semaforo
y
```

SEMAFORO




0	Verde
1	Verde
2	Rojo
3	Verde
4	Rojo
...	...
1063	Rojo
1064	Rojo
1065	Rojo
1066	Verde

▼ Exploracion de los datos

Se exploran los datos estadísticos de las columnas de las sustancias contaminantes
df_sust.describe()

	ALC_mg/L	CONDUCT_mS/cm	SDT_M_mg/L	FLUORUROS_mg/L	DUR_mg/L	COLI_
count	1054.000000	1054.000000	1054.000000	1054.000000	1054.000000	
mean	234.695266	1142.726471	896.945797	1.078547	349.893584	
std	111.147849	1248.990617	2765.757924	1.931204	360.960153	
min	26.640000	110.000000	101.200000	0.200000	20.000000	
25%	164.257500	506.000000	338.050000	0.269475	121.512000	
50%	215.825000	820.000000	551.400000	0.506950	245.994450	
75%	292.930000	1328.000000	915.600000	1.142400	455.617200	
max	1650.000000	18577.000000	82170.000000	34.803300	3810.692200	

```
# Grafico de cajas
sns.boxplot(data = df_sust, orient="h")
plt.show()
```

Se visualiza la matriz de correlacion

```
corrs = df_sust.corr()
```

```
sns.set(rc = {'figure.figsize':(15,10)})
```

```
sns.heatmap(corrs, vmin = -1, vmax = 1, cmap = "BuGn", annot= True, fmt=".3f")
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7ff4e1c778d0>
```

```
# Exploracion de la varianza
print('Varianza correspondiente a cada columna:')
print(df_sust.var())
print('\nTotal de varianza: ',sum(df_sust.var()))
print('\nProporcion de varianza de cada columna:')
print(np.round(df_sust.var()/sum(df_sust.var()),3)*100)
```

```
Varianza correspondiente a cada columna:
```

```
ALC_mg/L          1.235384e+04
CONDUCT_mS/cm     1.559978e+06
SDT_M_mg/L        7.649417e+06
FLUORUROS_mg/L    3.729549e+00
DUR_mg/L          1.302922e+05
COLI_FEC_NMP/100_mL 4.267140e+06
N_NO3_mg/L        7.019645e+01
AS_TOT_mg/L       1.228557e-03
CD_TOT_mg/L       8.102546e-07
CR_TOT_mg/L       2.415279e-02
HG_TOT_mg/L       2.206552e-07
PB_TOT_mg/L       1.073068e-05
MN_TOT_mg/L       1.435322e-01
FE_TOT_mg/L       3.107290e+01
dtype: float64
```

```
Total de varianza: 13619286.03779883
```

```
Proporcion de varianza de cada columna:
```

```
ALC_mg/L          0.1
CONDUCT_mS/cm     11.5
SDT_M_mg/L        56.2
FLUORUROS_mg/L    0.0
DUR_mg/L          1.0
COLI_FEC_NMP/100_mL 31.3
N_NO3_mg/L        0.0
AS_TOT_mg/L       0.0
CD_TOT_mg/L       0.0
CR_TOT_mg/L       0.0
HG_TOT_mg/L       0.0
PB_TOT_mg/L       0.0
MN_TOT_mg/L       0.0
FE_TOT_mg/L       0.0
dtype: float64
```

Segun su estadística descriptiva y varianza, se aprecia como los valores entre columnas tienen diferentes escalas numéricas, lo cual produce un alto índice de varianza. No nos podemos fiar de estos valores debido a las diferentes magnitudes que se presentan.

```
# Escalamiento de los datos
scaler = MinMaxScaler()
scaled = scaler.fit_transform(df_sust)
```

```
scaled_df_sust = pd.DataFrame(scaled, columns=df_sust.columns)
scaled_df_sust.head()
```

	ALC_mg/L	CONDUCT_mS/cm	SDT_M_mg/L	FLUORUROS_mg/L	DUR_mg/L	COLI_FEC_NMP/100
0	0.125265	0.044945	0.006122	0.022443	0.051107	0.000
1	0.126497	0.026967	0.004194	0.021090	0.043541	0.000
2	0.109822	0.022852	0.002934	0.046368	0.026570	0.000
3	0.185024	0.031191	0.004599	0.026671	0.047453	0.000
4	0.174481	0.093735	0.013133	0.000991	0.120555	0.011

```
# Se explora nuevamente la varianza con los datos transformados
print('Varianza correspondiente a cada columna:')
print(scaled_df_sust.var())
print('\nTotal de varianza: ',sum(scaled_df_sust.var()))
print('\nProporcion de varianza de cada columna:')
print(np.round(scaled_df_sust.var()/sum(scaled_df_sust.var()),3)*100)
```

Varianza correspondiente a cada columna:

```
ALC_mg/L          0.004688
CONDUCT_mS/cm     0.004574
SDT_M_mg/L        0.001136
FLUORUROS_mg/L    0.003115
DUR_mg/L          0.009067
COLI_FEC_NMP/100_mL 0.007289
N_NO3_mg/L        0.004795
AS_TOT_mg/L       0.006283
CD_TOT_mg/L       0.000956
CR_TOT_mg/L       0.000967
HG_TOT_mg/L       0.001184
PB_TOT_mg/L       0.001863
MN_TOT_mg/L       0.001780
FE_TOT_mg/L       0.000974
dtype: float64
```

Total de varianza: 0.04867157843563119

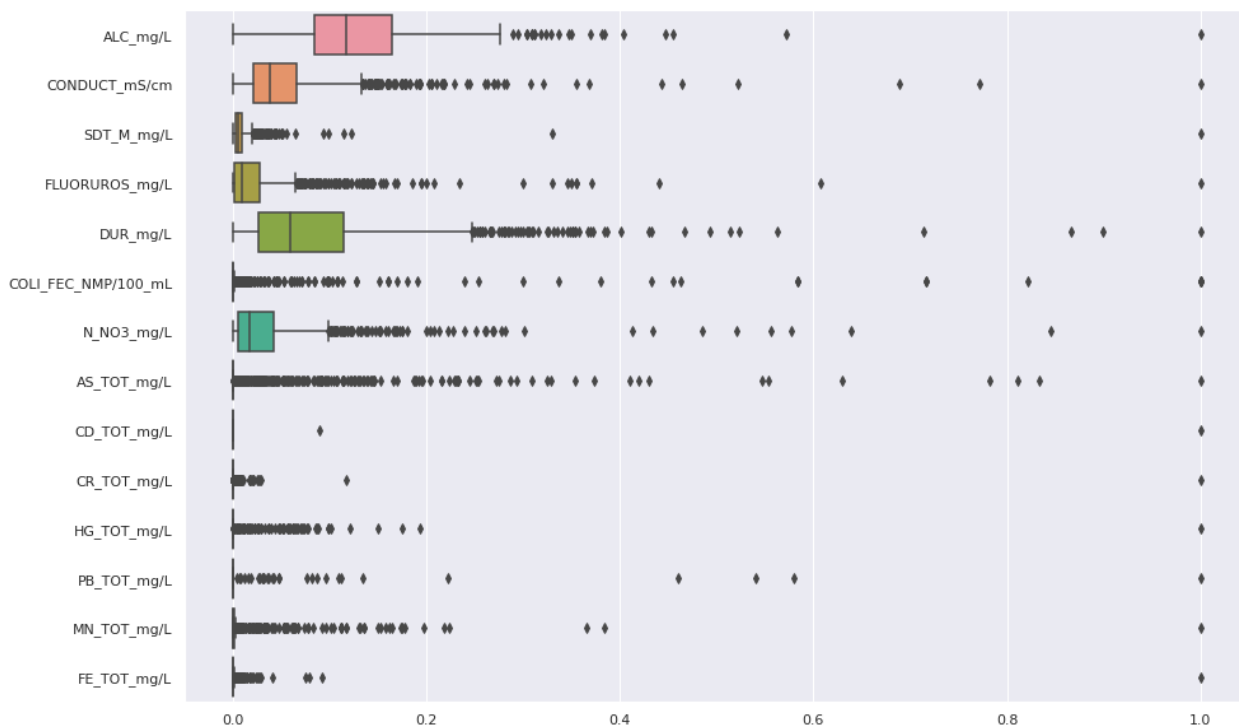
Proporcion de varianza de cada columna:

```
ALC_mg/L          9.6
CONDUCT_mS/cm     9.4
SDT_M_mg/L        2.3
FLUORUROS_mg/L    6.4
DUR_mg/L          18.6
COLI_FEC_NMP/100_mL 15.0
N_NO3_mg/L        9.9
AS_TOT_mg/L       12.9
CD_TOT_mg/L       2.0
CR_TOT_mg/L       2.0
HG_TOT_mg/L       2.4
PB_TOT_mg/L       3.8
MN_TOT_mg/L       3.7
```

FE_TOT_mg/L
dtype: float64

2.0

```
# Grafico de cajas
sns.boxplot(data = scaled_df_sust, orient="h")
plt.show()
```



```
scaled_df_sust.describe() #Datos estadísticos de dataframe escalado
```

	ALC_mg/L	CONDUCT_mS/cm	SDT_M_mg/L	FLUORUROS_mg/L	DUR_mg/L	COLI_F
count	1054.000000	1054.000000	1054.000000	1054.000000	1054.000000	
mean	0.128163	0.055923	0.009696	0.025389	0.087027	
std	0.068468	0.067634	0.033700	0.055810	0.095223	

Aun transformando los datos, en el grafico de cajas puede notar como la distribucion de los lados en cada columna no es uniforme y presentad una cantidad grande de outliers.


50%	0.116539	0.038447	0.005486	0.008871	0.059618
------------	----------	----------	----------	----------	----------

Relacion entre la calidad del agua y su ubicacion geografica utilizando Kmeans

Mediante una gráfica de dispersión procedemos a visualizar las cordenadas de cada uno de los cuerpos de agua de la base de datos.

```
# Graficamos los cuerpos de agua segun sus coordenadas
df_location.plot.scatter('LONGITUD','LATITUD')
```

WARNING:matplotlib.axes._axes:*c* argument looks like a single numeric RGB or RGBA
<matplotlib.axes._subplots.AxesSubplot at 0x7ff4dd498c50>



#Generamos dataframe con los datos de las coordenadas

df_location

df_location["COORDENADAS"] = list(zip(df_location.LONGITUD, df_location.LATITUD))


df_location["COORDENADAS"] = df_location["COORDENADAS"].apply(Point)

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:3: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: <https://pandas.pydata.org/pandas-docs/stable/user>

This is separate from the ipykernel package so we can avoid doing imports until
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:4: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: <https://pandas.pydata.org/pandas-docs/stable/user>
after removing the cwd from sys.path.



df_location.head() #Mostramos el dataframe generado con las coordenadas

	LONGITUD	LATITUD	COORDENADAS	
0	-102.02210	22.20887	POINT (-102.0221 22.20887)	
1	-102.20075	21.99958	POINT (-102.20075 21.99958)	
2	-102.28801	22.36685	POINT (-102.28801 22.36685)	
3	-102.29449	22.18435	POINT (-102.29449 22.18435)	
4	-110.24480	23.45138	POINT (-110.2448 23.45138)	

#Creamos Geodataframe

Mapa_Geo_Mex = gpd.GeoDataFrame(df_location, geometry="COORDENADAS")

world = gpd.read_file(gpd.datasets.get_path("naturalearth_lowres"))

world = world.set_index("iso_a3")

world.name.unique()

fig, gax = plt.subplots(figsize=(10,10))

```
world.query("name == 'Mexico']").plot(ax=gax, edgecolor='black',color='white')

gax.set_xlabel('LATITUD')
gax.set_ylabel('LONGITUD')

gax.spines['top'].set_visible(False)
gax.spines['right'].set_visible(False)

#Graficamos mapa
Mapa_Geo_Mex.plot(ax=gax, color='Blue', alpha = 0.5)

#Mostramos dataframe generado
Mapa_Geo_Mex
```

	LONGITUD	LATITUD	COORDENADAS
0	-102.02210	22.20887	POINT (-102.02210 22.20887)
1	-102.20075	21.99958	POINT (-102.20075 21.99958)

#Aplicamos Kmeans para generar la grafica de codo, que nos ayudara a determinar la cantidad d

#Definimos Kmeans usando las columnas de latitud y longitud

```
Cluster_num = range(1,10)
```

```
kmeans_cluster = [KMeans(n_clusters=i) for i in Cluster_num]
```

```
Y_axis = df_location[['LATITUD']]
```

```
X_axis = df_location[['LONGITUD']]
```

```
train_kmeans = [kmeans_cluster[i].fit(Y_axis).score(Y_axis) for i in range(len(kmeans_cluster
```

#Grafica de codo

```
plt.figure(figsize=(10,6))
```

```
plt.plot(Cluster_num, train_kmeans)
```

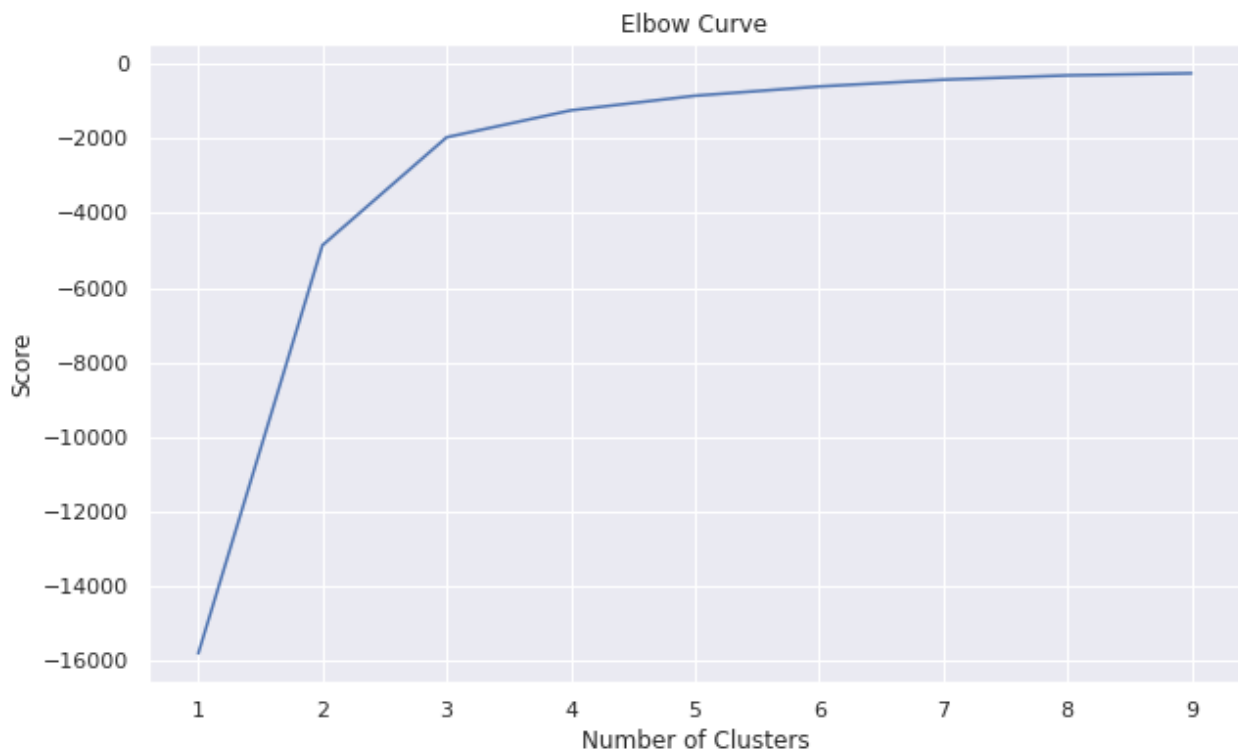
```
plt.xlabel('Number of Clusters')
```

```
plt.ylabel('Score')
```

```
plt.title('Elbow Curve')
```

#Mostramos grafica

```
plt.show()
```



Según la gráfica de codo podemos observar que el valor de clústeres adecuado es de 3, ya que a partir del cuarto se aprecia una tendencia de mantenerse constante.


```
#Generamos los 3 centroides de los clusters
X = df[['LONGITUD', 'LATITUD']]

#Usamos calculo de kmeans con 3 clusters
kmeans = KMeans(n_clusters=3).fit(X)

#Obtenemos centroides
centroids = kmeans.cluster_centers_

#Prediccion de kmeans
labels = kmeans.predict(X)

#Definimos dataframe con la informacion de los centroides de los clusters
df_centroids = pd.DataFrame(centroids)
df_centroids["Coordinates"] = list(zip(df_centroids[0], df_centroids[1]))
df_centroids["Coordinates"] = df_centroids["Coordinates"].apply(Point)

#creamos Geodataframe de los centroides
centroids_plot = gpd.GeoDataFrame(df_centroids, geometry="Coordinates")
centroids_plot
```


	0	1	Coordinates
0	-101.715581	22.271624	POINT (-101.71558 22.27162)
1	-90.698434	19.475165	POINT (-90.69843 19.47516)
2	-110.740896	28.420375	POINT (-110.74090 28.42038)

```
# Conteo de cuerpos de agua de acuerdo a su respectivo color de semaforo
df['SEMAFORO'].value_counts()
```

```
Verde      427
Rojo       382
Amarillo   245
Name: SEMAFORO, dtype: int64
```

```
#Reemplazamos el nombre del color de semaforo, ya que el codigo para graficar solicita los nom
y['SEMAFORO_plot'] = y['SEMAFORO'].replace(to_replace = "Verde", value = "green")
y['SEMAFORO_plot'].replace(to_replace = "Rojo", value = "red", inplace=True)
y['SEMAFORO_plot'].replace(to_replace = "Amarillo", value = "yellow", inplace=True)

#Mostramos dataframe resultante
y
```

	SEMAFORO	SEMAFORO_plot	
0	Verde	green	
1	Verde	green	
2	Rojo	red	
3	Verde	green	
4	Rojo	red	
...	
1063	Rojo	red	
1064	Rojo	red	
1065	Rojo	red	


```
#Generamos coordenada concatenando la latitud y la longitud
Mapa_Geo_Mex['Coordenada'] = Mapa_Geo_Mex['LATITUD'] + Mapa_Geo_Mex['LONGITUD']
```

```
#Creamos diccionario donde almacenamos la cordenada y el color de semaforo
semaforo_plot = dict(zip(Mapa_Geo_Mex.Coordenada, y['SEMAFORO_plot']))
```

```
#Graficamos el mapa
lat = Mapa_Geo_Mex.iloc[0]['LATITUD']
lng = Mapa_Geo_Mex.iloc[0]['LONGITUD']
map = folium.Map(location=[lng, lat], zoom_start=1)
```

```
for _, row in Mapa_Geo_Mex.iterrows():
    folium.CircleMarker(
        location=[row["LATITUD"], row["LONGITUD"]],
        radius=5,
        weight=1,
        fill=True,
        fill_color=semaforo_plot[row["Coordenada"]],
        color=semaforo_plot[row["Coordenada"]]
    ).add_to(map)
color='black'
```

```
for _, row in Mapa_Geo_Mex.iterrows():
    folium.CircleMarker(
        location=[row[1], row[0]],
        radius=5,
        weight=1,
        fill=True,
        fill_color=color,
        color=color
    ).add_to(map)
map
```

```
#Graficamos los clusters
fig, gax = plt.subplots(figsize=(15,10))
colores = ['black', 'purple', 'green']
color_asig = []

for row in labels:
    color_asig.append(colores[row])

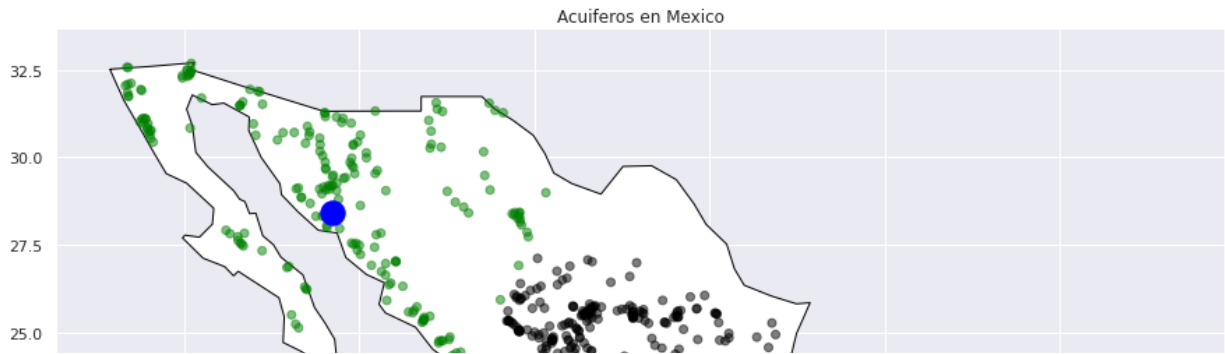
#Definimos parametros de grafica
world.query("name == 'Mexico'").plot(ax = gax, edgecolor='black', color='white')

Mapa_Geo_Mex.plot(ax=gax, color=color_asig, alpha = 0.5)
centroids_plot.plot(ax=gax, color='blue', alpha = 1, markersize = 300)

gax.set_xlabel('longitude')
gax.set_ylabel('latitude')
gax.set_title('Acuiferos en Mexico')

gax.spines['top'].set_visible(False)
gax.spines['right'].set_visible(False)

plt.show()
```



```
#Agregamos la columna semaforo y numero de cluter
Mapa_Geo_Mex['SEMAFORO']= y['SEMAFORO']
Mapa_Geo_Mex['CLUSTER'] = labels
Mapa_Geo_Mex
```

	LONGITUD	LATITUD	COORDENADAS	Coordenada	SEMAFORO	CLUSTER
0	-102.02210	22.20887	POINT (-102.02210 22.20887)	-79.81323	Verde	0
1	-102.20075	21.99958	POINT (-102.20075 21.99958)	-80.20117	Verde	0
2	-102.28801	22.36685	POINT (-102.28801 22.36685)	-79.92116	Rojo	0
3	-102.29449	22.18435	POINT (-102.29449 22.18435)	-80.11014	Verde	0
4	-110.24480	23.45138	POINT (-110.24480 23.45138)	-86.79342	Rojo	2
...
1063	-99.54191	24.76036	POINT (-99.54191 24.76036)	-74.78155	Rojo	0
1064	-99.70099	24.78280	POINT (-99.70099 24.78280)	-74.91819	Rojo	0
...

Resultados de agrupamiento de latitudes y longitudes con Kmeans en el mapa de Mexico

```
#Cambiamos el nombre del color a ingles
Mapa_Geo_Mex['SEMAFORO_Plot'] = Mapa_Geo_Mex['SEMAFORO'].replace(to_replace = "Verde", value
Mapa_Geo_Mex['SEMAFORO_Plot'].replace(to_replace = "Rojo", value = "red", inplace=True)
Mapa_Geo_Mex['SEMAFORO_Plot'].replace(to_replace = "Amarillo", value = "yellow", inplace=True)
```

```
labels_semaforo = Mapa_Geo_Mex['SEMAFORO_Plot'].tolist()
Mapa_Geo_Mex['SEMAFORO_Plot']

0      green
1      green
2      red
3      green
4      red
...
1063   red
1064   red
1065   red
1066   green
1067   green
Name: SEMAFORO_Plot, Length: 1054, dtype: object

#Graficamos el mapa con los clusters y los colores de semaforo individual de cada cuerpo de a
fig, gax = plt.subplots(figsize=(15,10))

colores = ['green','yellow','red']

color_asig = []

for j in range(0,1054):
    color_asig.append(labels_semaforo[j])

world.query("name == 'Mexico'").plot(ax = gax, edgecolor='black', color='white')

Mapa_Geo_Mex.plot(ax=gax, color=color_asig, alpha = 0.5, legend=True)

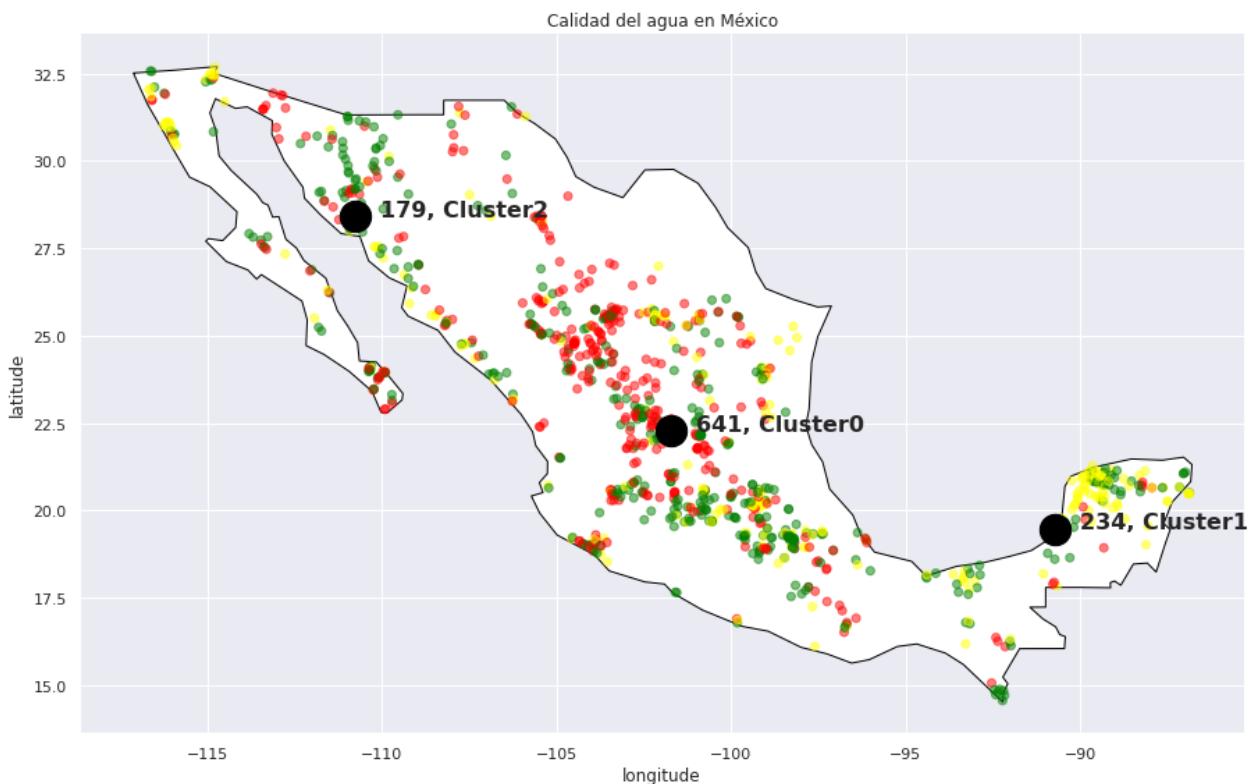
plt.scatter(centroids[:, 0], centroids[:, 1], c='black', s=500, alpha=1)

list_names_regions = ["Cluster0", "Cluster1", "Cluster2"]
list_stores_cluster = pd.DataFrame(labels).value_counts().to_list()
for i, txt in enumerate(list_stores_cluster):
    plt.annotate(str(txt)+ ", " + list_names_regions[i], (centroids[i,0], centroids[i,1]), xy

gax.set_xlabel('longitude')
gax.set_ylabel('latitude')
gax.set_title('Calidad del agua en México')

gax.spines['top'].set_visible(False)
gax.spines['right'].set_visible(False)

plt.show()
```



```
#Determinamos la moda de cada cluster
```

```
mode_list=[]
```

```
for i in range(0,3):
```

```
    df_cluster = pd.DataFrame()
```

```
    df_cluster = Mapa_Geo_Mex[Mapa_Geo_Mex.CLUSTER == i].copy()
```

```
    moda = df_cluster['SEMAFORO'].mode()[0]
```

```
    mode_list.append(modas)
```

```
len(mode_list)
```

```
centroids_plot['MODA'] = mode_list
```

```
centroids_plot
```

	0	1	Coordinates	MODA	
0	-101.715581	22.271624	POINT (-101.71558 22.27162)	Rojo	
1	-90.698434	19.475165	POINT (-90.69843 19.47516)	Amarillo	
2	-110.740896	28.420375	POINT (-110.74090 28.42038)	Verde	


```
#Relizamos el conteo de cada color de semaforo de cada uno de los clusters
```

```
Mapa_Geo_Mex["Cluster"] = labels
```

```
clusters_dict = {}
for i in range(3):
    if "Cluster"+str(i) not in clusters_dict:
        clusters_dict["Cluster"+str(i)] = []
    clusters_dict["Cluster"+str(i)] = Mapa_Geo_Mex[Mapa_Geo_Mex["Cluster"] == i].groupby(by="SE

#Graficamos el conteo de las clases de cada cluster
Cluster_Semaforo = pd.DataFrame(clusters_dict)
Cluster_Semaforo.transpose().plot.bar(color={"Amarillo": "yellow", "Rojo": "red", "Verde": "g
```

<matplotlib.axes._subplots.AxesSubplot at 0x7ff4d9f52cd0>



```
#Graficamos los clusters con sus color de semaforo basado en la moda
fig, gax = plt.subplots(figsize=(15,10))

colores = ['green','yellow','red']

color_asig = []
```



```
for j in range(0,1054):
    color_asig.append(labels_semaforo[j])

world.query("name == 'Mexico'").plot(ax = gax, edgecolor='black', color='white')

Mapa_Geo_Mex.plot(ax=gax, color=color_asig, alpha = 0.5, legend=True)

plt.scatter(centroids[:, 0], centroids[:, 1], c=["red", "yellow", "green"], s=500, alpha=1)

list_names_regions = ["Cluster0", "Cluster1", "Cluster2"]
list_stores_cluster = pd.DataFrame(labels).value_counts().to_list()
for i, txt in enumerate(list_stores_cluster):
    plt.annotate(str(txt)+ ", " + list_names_regions[i], (centroids[i,0], centroids[i,1]), xy

gax.set_xlabel('longitude')
gax.set_ylabel('latitude')
gax.set_title('Calidad del agua en México')

gax.spines['top'].set_visible(False)
gax.spines['right'].set_visible(False)

plt.show()
```



Calidad del agua en México

CONCLUSIONES

Gracias a este ejercicio hemos descubierto datos interesantes sobre la calidad del agua en el país, así como su relación con su ubicación geográfica.

Gracias al uso de Kmeans hemos podido determinar los conjuntos o zonas de cuerpos de agua así como su relación basada en su calidad. Notamos y concluimos que la mejor calidad de agua basada en la moda de los conjuntos o clusters es la que se encuentra en la zona noroeste, mientras que la peor calidad de agua la ubicamos en el centro del país. En la parte sur de México observamos que la categoría dominante es la amarilla.

Ahora bien si prestamos atención a la grafica de barras notamos que aunque la moda del cluster noroeste es verde, hay una cantidad similar de cuerpos de agua con semáforo rojo, lo que nos indica que en proporción están casi parejos. Siguiendo esa tónica, podríamos considerar que la zona que menos semáforos rojos tiene es la zona sur (cluster1)



[Productos de pago de Colab](#) - [Cancelar contratos](#)

✓ 0 s completado a las 1:16

● ✕